




南京航空航天大学
NANJING UNIVERSITY OF AERONAUTICS AND ASTRONAUTICS


人工智能内容生成 (AIGC) 技术与应用

回顾

- VAE 用自编码器+变分推断建模数据分布，但生成结果比较模糊
- GAN 用对抗学习优化建模数据分布，生成质量好一些但训练不稳定
- VAE 和GAN生成过程都是使用一次模型迭代生成数据，总体生成效果不佳



- 扩散模型通过多步模型迭代，实现逐步去噪，逐渐提升质量，生成效果好



共同思路

简单分布采样 + 复杂映射 = 复杂分布采样

- VAE 和 GAN 都是一步映射：从一个隐变量 z 直接生成 x 。
- 扩散模型是多步映射：从简单随机噪声 z 逐步去噪到干净图像 x 。

自回归生成式模型

- 不是从隐变量映射到数据，
- 而是把数据分布分解成一系列条件分布的乘积
- 然后逐个元素地生成

关于AIGC技术，你有什么特别推荐的吗



☒ 已思考 (用时 3 秒) ▾

- 嗯，用户询问关于AIGC技术的特别推荐。

这个问题比较开放，用户可能是在寻找具体的工具、学习资源、应用方向或者行业洞察。我需要先明确“推荐”的范围，避免泛泛而谈。考虑到AIGC领域发展迅速，我的知识有截止日期，所以需要先说明这一点，并建议用户查询最新信息。

我可以从几个方面来组织推荐：一是当前主流且表现突出的工具或平台，按文本、图像、视频等模态分类；二是对技术爱好者或从业者可能有用的学习资源或关键概念；三是一些值得关注的应用趋势。回答时应该保持结构清晰，但避免过于冗长。最后可以引导用户提供更具体的兴趣点以便进一步交流。

AIGC（人工智能生成内容）领域发展极快，我的知识截止于2025年5月，因此部分最新工具（如2025年底至2026年新发布的模型）可能不在列表中。为了给你最准确的推荐，建议你打开我的[联网搜索功能](#)，查询当下最新的排名和评测。

基于截至2025年中后期的行业格局，以下是我根据不同需求维度的特别推荐：

1. 文本生成（大语言模型）

如果你追求**综合能力最强**：

- **Claude (An



第六章

自回归生成式模型


目录

- **第一节 联合分布建模与条件分布建模**
- **第二节 自回归模型基本概念**
- **第三节 典型自回归网络结构-RNN**
- **第四节 典型自回归网络结构-Attention**

联合数据分布建模


现实中大部分数据建模都是需要建模一个**联合数据分布**

图像



28*28个像素的联合分布

视频



28*28*24个像素的联合分布

文字

1975年二、三月间，一个平平常常的日子，细蒙蒙的雨丝夹着一星半点的雪花，正纷纷淋淋地向大地飘洒着。

50个字的联合分布


$$P(x_1, x_2, \dots, x_n)$$

一个直观想法：用独立分布来建模联合分布

$$p(x_1, x_2) = p(x_1)p(x_2)$$

条件分布等于边缘分布

$$p(x_2|x_1) = p(x_2)$$




现实世界数据总是涉及变量之间的依赖关系

$$p(x_1, x_2) \neq p(x_1)p(x_2)$$

条件分布不等于边缘分布



$$p(x_2|x_1)$$



如何建模联合数据分布呢？

➤ 方案 1：使用元素独立隐变量建模（如 VAE/GAN）

- 构建映射：**元素独立**隐变量 $\Rightarrow$ **元素关联**数据
- 高维数据（例如 28×28 像素）各元素间**条件独立**
- 通常采用低维隐变量 z
- 是一个很好的构建模块，但往往不够充分



VAE 在 784 (28*28) 维 MNIST 数据上的结果



(a) 2维隐空间

(b) 5维隐空间

(c) 10维隐空间

(d) 20维隐空间

隐变量独立假设太强，无法建模像素间复杂的依赖关系。

如何建模联合分布?

- 方案1：使用元素独立隐变量建模
- 方案2：通过条件分布进行建模

条件分布建模


- 链式法则：任何联合分布都可以写成条件概率乘积的形式

$$p(A, B, C) = p(A)p(B|A)p(C|A, B)$$

条件分布建模

- 链式法则：任何联合分布都可以写成条件概率的乘积形式


$$p(A, B, C) = p(A)p(B|A)p(C|A, B)$$



条件分布建模

- 链式法则：任何联合分布都可以写成条件概率的乘积形式


$$p(A, B, C) = p(A)p(B|A)p(C|A, B)$$



条件分布建模

- 链式法则：任何联合分布都可以写成条件概率的乘积形式

$$p(A, B, C) = p(A)p(B|A)p(C|A, B)$$



条件分布建模

➤ 链式法则：任何联合分布都可以写成条件概率的乘积形式

$$p(A, B, C) = p(A)p(B|A)p(C|A, B)$$

可以以任意顺序分解

$$\begin{aligned} p(A, B, C) &= p(A)p(B|A)p(C|A, B) \\ &= p(A)p(C|A)p(B|A, C) \\ &= p(B)p(A|B)p(C|A, B) \\ &= p(B)p(C|B)p(A|B, C) \\ &= p(C)p(A|C)p(B|A, C) \\ &= p(C)p(B|C)p(A|B, C) \end{aligned}$$

条件分布建模

- 链式法则：任何联合分布都可以写成条件概率的乘积形式

$$p(A, B, C) = p(A)p(B|A)p(C|A, B)$$


可以以任意划分分解

$$\begin{aligned} p(A, B, C, D) &= p(A, B)p(C, D|A, B) \\ &= p(C, D)p(A, B|C, D) \\ &= p(A, B, C)p(D|A, B, C) \\ &= \dots \end{aligned}$$

案例研究：条件分布建模

- 案例1： 对输入 x 包含的多个元素进行划分
 - 如：基于文本词元或像素的自回归模型


$$p(x_1, x_2, \dots, x_n) = p(x_1)p(x_2|x_1)\dots p(x_n|x_1, x_2, \dots, x_{n-1})$$



案例研究：条件分布建模

- 案例2：数据分布的渐进式依赖变换
 - 示例：扩散模型


$$p(x_{0:T}) = p(x_T)p(x_{T-1}|x_T)\dots p(x_1|x_2)p(x_0|x_1)$$



条件分布建模

➤ 用神经网络为每一个条件分布建模

$$p(A, B, C) = p_{\theta}(A)p_{\phi}(B|A)p_{\psi}(C|A, B)$$



条件分布建模

- 用神经网络为每一个条件分布建模

$$p(A, B, C) = p_{\theta}(A)p_{\phi}(B|A)p_{\psi}(C|A, B)$$


- 注意:

- 对 $p(A, B, C)$ 进行参数化与对 $p(C | A, B)$ 进行参数化有何不同?
 - $p(A, B, C)$ 涉及3个变量
 - $p(C | A, B)$ 涉及1个变量和2个条件（条件是网络的输入）
- 权重共享?
 - 理论上，每个 p 有自己的权重
 - 权重共享意味着引入了归纳偏差（后续讨论）

依赖图

- 分解联合分布的过程等价于引入依赖图
- 依赖图反映了先验知识


$$p(A, B, C) = p(A)p(B|A)p(C|A, B)$$



依赖图

- 某些依赖图可能会引出更简单的分布




$$p(A, B, C) = p(A)p(B|A)p(C|A, B) \quad p(A, B, C) = p(C)p(B|C)p(A|B, C)$$



两种表述都是有效的，但其中一种可能比另一种更容易学习。

依赖图

- 某些依赖图可能会引出更简单的分布



总结-如何建模联合概率

- 使用条件概率的乘积建模联合分布
- 条件概率的设定可以是任意顺序、任意元素划分
- 不同的依赖图设定方式暗含着一些先验知识。
- 部分设定任务更简单

目录

- 第一节 联合分布建模与条件分布建模
- 第二节 自回归模型基本概念
- 第三节 典型自回归网络结构-RNN
- 第四节 典型自回归网络结构-Attention



自回归模型基本概念

自回归

➤ 什么是自回归

- “自”：指数据源于自身，即利用“序列”中**前面位置的数据来预测后面位置的数据**。
- “回归”：指的是一种**预测行为**。在统计学中，回归分析就是寻找变量之间关系的数学方法。
- “自回归”指的是推理时的行为。
- 训练时不一定采用自回归方式（例如，teacher forcing）。


自回归模型基本概念

自回归模型

一般而言，自回归是一种通过条件分布的乘积来建模联合分布的方式：

$$\begin{aligned} p(x_1, x_2, \dots, x_n) &= p(x_1)p(x_2|x_1)\dots p(x_n|x_1, x_2, \dots, x_{n-1}) \\ &= \prod_{i=1}^n p(x_i|x_1, x_2, \dots, x_{i-1}) \end{aligned}$$

➤ 从概念上讲 x 可以是**任意形式的表示**



- 不一定是序列或时序的
- 例如：一个向量的所有维度
- 例如：二维、三维或高维数组


自回归模型基本概念

自回归模型

一般而言，自回归是一种通过条件分布的乘积来建模联合分布的方式：

$$\begin{aligned} p(x_1, x_2, \dots, x_n) &= p(x_1)p(x_2|x_1)\dots p(x_n|x_1, x_2, \dots, x_{n-1}) \\ &= \prod_{i=1}^n p(x_i|x_1, x_2, \dots, x_{i-1}) \end{aligned}$$

➤ 从概念上讲 x 可以是**任意循序和划分**



- 顺序：例如，逆序也是有效的
- 划分：例如，每个 x_i 可以是标量、向量或张量

自回归模型基本概念


自回归模型

一般而言，自回归是一种通过条件分布的乘积来建模联合分布的方式：

$$\begin{aligned} p(x_1, x_2, \dots, x_n) &= p(x_1)p(x_2|x_1)\dots p(x_n|x_1, x_2, \dots, x_{n-1}) \\ &= \prod_{i=1}^n p(x_i|x_1, x_2, \dots, x_{i-1}) \end{aligned}$$

➤ 从每个 $p(\cdot | \cdot)$ 可以是**任意形式**

- 例如：查找表、树结构、神经网络，或混合形式
- 例如：离散变量或连续变量




自回归模型基本概念

自回归模型

一般而言，自回归是一种通过条件分布的乘积来建模联合分布的方式：

$$\begin{aligned} p(x_1, x_2, \dots, x_n) &= p(x_1)p(x_2|x_1)\dots p(x_n|x_1, x_2, \dots, x_{n-1}) \\ &= \prod_{i=1}^n p(x_i|x_1, x_2, \dots, x_{i-1}) \end{aligned}$$

- 这种分解方式是精确的，没有引入任何近似。
- 根据链式法则，这种分解总是成立的。



VAE、扩散模型并不是精确求解

VAE, DDPM中最大化似然估计都是通过最大化置信下界来近似

$$\text{VAE} \quad \text{最大化} \log p_{\theta}(x) \xrightarrow{\geq} \text{最大化} E_{q(z|x)} [\log (\frac{p(x,z)}{q(z|x)})]$$

$$\text{DDPM} \quad \text{最大化} \log p_{\theta}(x) \xrightarrow{\geq} \text{最大化} E_{q(x_1:x_T|x_0)} [\log (\frac{p(x_0:x_T)}{q(x_1:x_T|x_0)})]$$


**但自回归模型的分解是精确的，
如果每个条件分布都建模得完美，那联合分布也是完美的**

自回归模型基本概念

自回归模型

一般而言，自回归是一种通过条件分布的乘积来建模联合分布的方式：

$$\begin{aligned} p(x_1, x_2, \dots, x_n) &= p(x_1)p(x_2|x_1)\dots p(x_n|x_1, x_2, \dots, x_{n-1}) \\ &= \prod_{i=1}^n p(x_i|x_1, x_2, \dots, x_{i-1}) \end{aligned}$$




- 这种分解方式是精确的，没有引入任何近似。
- 根据链式法则，这种分解总是成立的。
- **但某些分解方式更容易建模：这就是“归纳偏差”。**

自回归模型基本概念

归纳偏差

对问题的先验假设（在建模之前就做出的选择）

$$p(A, B, C) = p(A)p(B|A)p(C|A, B) \quad p(A, B, C) = p(C)p(B|C)p(A|B, C)$$




我们希望分解后能得到更简单的分布。

自回归模型基本概念

归纳偏差

我们希望分解后能得到更简单的分布。

生成文字时，我们希望下一个单词的预测概率尽量集中，而不是分散在多个词上。




我今天吃了一碗__

自回归模型基本概念

归纳偏差

我们希望分解后能得到更简单的分布。

- 示例：“下一个词元预测”
- 时序建模意味着一种归纳偏差





自回归模型基本概念

归纳偏差

我们希望分解后的各个分布能够由 “**相似**” 的神经网络来表示。

$$p(x_1, x_2, \dots, x_n) = \underbrace{p_\theta(x_1)}_{\text{blue}} \underbrace{p_\theta(x_2|x_1)}_{\text{orange}} \dots \underbrace{p_\theta(x_n|x_1, x_2, \dots, x_{n-1})}_{\text{grey}}$$

- 从概念上讲，这些 $p(\cdot | \cdot)$ 是不同的映射关系
- 但我们通过**共享架构**（MLP、RNN、Transformer.....）来建模它们
- 并且**共享权重 θ**



自回归模型基本概念

归纳偏差

(回顾)：这种分解方式是精确的，没有引入任何近似。

$$p(x_1, x_2, \dots, x_n) = p(x_1)p(x_2|x_1) \dots p(x_n|x_1, x_2, \dots, x_{n-1})$$

➤ 但归纳偏差会引入近似：

- 共享架构、**共享权重**
- 特定分解方式

**这种近似在实践中通常是良性的，
减少了参数量，让训练更稳定**

自回归模型基本概念

表示单个条件分布

$$p_{\theta}(x_i | \underbrace{x_1, x_2, \dots, x_{i-1}})$$


- 网络输入: $x_1, x_2, \dots, x_{i-1}$
- 网络输出: x_i 的一个分布
 - 连续分布 
 - 离散分布 
- 注意:
 - 对于离散分布, 这个网络的行为类似于分类 (即自回归中的“回归”部分)
 - 离散分布在自回归模型中很常见, 但并非必须

自回归模型基本概念

推理：自回归

➤ 右图暗含着如下过程

$$\begin{aligned} & p(x_1, x_2, \dots, x_n) \\ &= p(x_1)p(x_2|x_1) \dots p(x_n|x_1, x_2, \dots, x_{n-1}) \end{aligned}$$




自回归模型基本概念

推理：自回归

➤ 网络建模 $p(x_2|x_1)$


- 1一个输入
- 1个输出



自回归模型基本概念

推理：自回归


- 网络建模 $p(x_3|x_{1,2})$
 - 2一个输入
 - 1个输出
- 输入：前几步的输出



自回归模型基本概念

推理：自回归


- 网络建模 $p(x_4|x_{1,2,3})$
 - 3一个输入
 - 1个输出
- 输入：前几步的输出



自回归模型基本概念

推理：自回归


- 网络建模 $p(x_5 | x_{1,2,3,4})$
 - 4个输入
 - 1个输出
- 输入：前几步的输出



自回归模型基本概念

推理：自回归


- 网络建模 $p(x_6 | x_{1,2,3,4,5})$
 - 5一个输入
 - 1个输出
- 输入：前几步的输出



自回归模型基本概念

推理：自回归


- 一个递归过程
- 信息从左到右流动：每一步的输出反馈为下一步的输入
- 推理式**串行**的



自回归模型基本概念

训练：自回归

- 计算网络输出与真实样本的差距
- 利用梯度回传算法，更新网络参数




自回归模型基本概念

训练：自回归

考虑 x_6 的一条梯度路径：

- 要经过前面所有的输出.....
- 要经过前面所有的采样操作.....
- 要经过前面所有的网络




一条梯度路径

自回归模型基本概念

训练：自回归

考虑 x_6 的**完整**梯度路径：

- 要经过前面所有的输出.....
- 要经过前面所有的采样操作.....
- 要经过前面所有的网络




按照推理图来训练自回归模型是不可行的

完整梯度路径

自回归模型基本概念

训练：自回归

- 1. 采样操作是不可导的
- 2. 梯度路径太长，会导致梯度消失或爆炸
- 3. 计算量巨大——每一步的梯度都要一路回传到起点



按照推理图来训练自回归模型是不可行的


完整梯度路径

自回归模型基本概念

训练：自回归

➤ Teacher-forcing (教师强制)

- 输入并非来自上一步的输出
- 输入来自真实数据




自回归模型基本概念

训练：自回归

➤ Teacher-forcing

- 输入并非来自上一步的输出
- 输入来自真实数据



网络块之间没有串行的依赖关系

自回归模型基本概念


训练：自回归

➤ Teacher-forcing

- 输入并非来自上一步的输出
- 输入来自真实数据

➤ 优点：

- 反向传播路径大大缩短



自回归模型基本概念


训练：自回归

➤ Teacher-forcing

- 输入并非来自上一步的输出
- 输入来自真实数据

➤ 优点：

- 反向传播路径大大缩短
- 真实数据输入可以简化训练难度



自回归模型基本概念

训练：自回归

➤ Teacher-forcing


- 输入并非来自上一步的输出
- 输入来自真实数据

➤ 优点：

- 反向传播路径大大缩短
- 真实数据输入可以简化训练

➤ 缺点：


- 训练与推理不一致
- **训练-推理分布偏移**：模型看不到自己的错误



自回归模型基本概念

运行示例：在MNIST上的自回归模型


- 把图像看作像素序列



自回归模型基本概念

运行示例：在MNIST上的自回归模型


- 把图像看作像素序列
- 按光栅顺序扫描



自回归模型基本概念

运行示例：在MNIST上的自回归模型


- 推断：自回归
 - 随机采样第一个像素



自回归模型基本概念

运行示例：在MNIST上的自回归模型


- 推断：自回归
 - 从 $p_{\theta}(x_2|x_1)$ 分布采样像素
- 图上标出的是上一步的输出，也是当前步的输入。
- 当前步骤的网格：
 - 1个输入
 - 1个预测



自回归模型基本概念

运行示例：在MNIST上的自回归模型

- 推断：自回归
 - 从 $p_{\theta}(x_n | x_1, \dots, x_{n-1})$ 分布采样像素
- 图上标出的是前n-1步的输出，也是当前步的输入
- 当前步骤的网格：
 - n-1个输入
 - 1个预测




自回归模型基本概念

运行示例：在MNIST上的自回归模型

➤ 训练：Teacher Forcing


- 通过 $p_{\theta}(x_n|x_1,\dots,x_{n-1})$ 来建模当前像素
- 作为当前步骤的输入来自**真实数据**
- 当前步骤的网络：
 - 输入 $(n-1)$ 个
 - 预测：1个



自回归模型基本概念

运行示例：在MNIST上的自回归模型

- 不涉及具体的网络架构
- 可以有多种网络架构：循环神经网络（RNN）
卷积神经网络（CNN）、Transformer
- 自回归定义的是"做什么"（what）
- 网络架构解决的是"怎么做"（how）





自回归模型

➤ 总结:

- 联合分布 $\Rightarrow$ 条件概率的乘积
- 归纳偏差: 共享架构、共享权重、特定的顺序
- 推理: 自回归
- 训练: 教师强制 Teacher Forcing

这些并不特定于某一种网络架构
自回归是一种建模范式, 不是一种网络

目录

- 第一节 联合分布建模与条件分布建模
- 第二节 自回归模型基本概念
- 第三节 典型自回归网络结构-RNN
- 第四节 典型自回归网络结构-Attention

典型自回归网络结构


自回归并非依赖于某种特定架构

➤ 右图实现了下面这个公式：

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i | x_1, x_2, \dots, x_{i-1})$$

➤ 在这个例子中：

- 5个网络
- 每一个网络有1到5个输入



自回归模型训练过程


典型自回归网络结构

自回归并非依赖于某种特定架构

➤ 右图实现了下面这个公式：

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i | x_1, x_2, \dots, x_{i-1})$$

我们能否**高效**地实现这一点？




典型自回归网络结构

自回归并非依赖于某种特定架构

➤ 右图实现了下面这个公式：

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i | x_1, x_2, \dots, x_{i-1})$$

我们能否**高效**地实现这一点？




典型自回归网络结构

自回归并非依赖于某种特定架构

➤ 右图实现了下面这个公式：

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i | x_1, x_2, \dots, x_{i-1})$$

我们能否**高效**地实现这一点？



典型自回归网络结构

自回归并非依赖于某种特定架构


➤ 我们可以实现这个公式：

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i | x_1, x_2, \dots, x_{i-1})$$


通过一个网络：

- 共享网络结构
- 共享网络权重
- **共享计算**

并满足约束： x_i 只依赖于 $x_j, j < i$




典型自回归网络结构



RNN


RNN 的优点是参数量小、内存友好，
但无法并行训练（时间步必须串行）



Attention



Attention 的优点是训练时可以完全并行，
且可以直接建模长距离依赖

简介：用于自回归的循环神经网络（RNN）



- 输入 (x_i) 是第 i 个元素
- 隐状态 (h_i) 压缩了 ($x_1, \dots, x_i$) 的所有历史信息
- 输出是 ($p(x_{i+1}|x_1, \dots, x_i)$) 的分布


简介：用于自回归的循环神经网络（RNN）



用一个网络模块代表

典型自回归网络结构-RNN

简介：用于自回归的循环神经网络（RNN）



$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i | x_1, x_2, \dots, x_{i-1})$$

1. 为什么需要自回归?
2. 自回归建模是什么?
3. 用什么神经网络实现? (未完待续)