



人工智能内容生成 (AIGC) 技术与应用

第七章

大语言模型

目录

- **第一节 大语言模型简介**
- **第二节 大语言模型的构建方法**
- **第三节 大语言模型的应用**



大语言模型简介

第七章 大语言模型

大模型应用蓬勃发展




聊天助手



AI搜索



个人AI助手



氛围编程 (Vibe Coding)

第七章 大语言模型


自然语言处理 (NLP)

- **语言**是人类交流的工具，也是人类思维的载体。
 - 世界上正在使用的语言超过 1900 种。
 - 不同语言的结构各不相同。
- **自然语言**是人类的语言（例如：英语、法语、汉语）。
 - 与自然语言相对的是构造语言(如编程语言、形式逻辑语言等)



自然语言处理 (NLP)

- **自然语言处理 (NLP)** 是人工智能的一个分支，它帮助计算机理解、解释和处理人类语言。



NLP任务数种类繁多

词法分析

分词
词元化
新词识别
形态分析
词性标注
拼写纠错

句子分析

组块分析
超标记
成分句法分析
依存句法分析
语言建模
语言识别

语义分析

词义消歧
语义角色标注
抽象意义表示解析
框架语义解析
一阶谓词演算
词向量/句向量/段落向量

信息抽取

命名实体识别/消歧
术语/术语表抽取
共指消解
关系抽取
事件抽取
情感分析

高级任务

机器翻译
文本摘要/文本简化
问答系统
对话系统
阅读理解
自动作文评分

第七章 大语言模型

数据标注难

- 标注任务的复杂性高
- 标注标准模糊，一致性低
- 标注成本高昂
- 低资源场景的标注困境



是否可以统一各类任务？

任务一



任务二



任务三



任务四



统一任务



统一数据集

是否可以利用无标签数据?

标注数据



无标注数据



语言模型发展——统计模型阶段

核心思想：用概率统计的方法对语言进行建模，通过从标注数据中估计参数来捕捉语言规律。

➤ 主要方法

- n-gram:用马尔可夫假设简化概率，统计词频预测文本。
- HMM（隐马尔可夫模型）：用隐状态生成观测词，统计状态转移概率
- CRF（条件随机场）：用全局条件概率建模序列，预测每个位置最可能的标签。

语言模型发展——统计模型阶段

核心思想：用概率统计的方法对语言进行建模，通过从标注数据中估计参数来捕捉语言规律。

每个任务需要独立建模、独立标注，模型无法复用，也无法利用无标注数据。

语言模型发展——词向量阶段

核心思想：用无标注数据学习词向量，作为下游任务的输入特征实现知识复用。

➤ 代表性工作：

- Word2Vec: 用一个词预测它的上下文 (CBOW) , 或用上下文预测这个词 (Skip-gram) , 通过预测任务迫使网络学习到词的向量表示。

开始利用无标注数据，但下游任务仍需独立建模，且每个任务仍需要大量标注数据。

语言模型发展——预训练语言模型阶段

核心思想：用无标注数据预训练整个网络，微调后即可适配所有下游任务，大幅减少标注需求

➤ 代表性工作

- BERT

架构：Transformer 编码器（双向）

预训练任务：掩码语言建模（MLM）

+ 下一句预测（NSP）

➤ 代表性工作

- GPT

架构：Transformer 解码器（单向）

预训练任务：自回归语言建模（预测下一个词）

自回归语言建模

学生们打开了他们的——

- 书
- 笔记本电脑
- 试卷
- 心扉



自回归语言建模——预测下一个词不简单

- 中国的首都是__
- 小芬对小芳说：“后天的大前天的后天，也就是昨天的昨天的大后天是我的生日，请来参加我的生日会。”小芳应该什么时候赴约呢？__
- 这天，柯南收到了一封来自大版的信...(此处省略数千字)...凶手是__
- $1234567 * 54321 + 1234567 / 2 = \underline{\hspace{1cm}}$

自回归语言建模

➤ 优化目标:

$$\mathcal{L} = -\frac{1}{n} \sum_{i=1}^n \log P(w_i | w_1, \dots, w_{i-1})$$


其中, $w = \{w_1, \dots, w_n\}$ 表示一个序列

自回归建模方式为统一所有NLP任务提供了可能, 但在预训练语言模型阶段, 仍需依赖下游任务的标注数据进行微调。

大而不同——尺度定律

➤ 训练模型的三要素：模型参数量 N ，数据量 D ，计算量 C

语言模型的性能真的能通过无限扩大参数量、数据量和计算量来持续提升吗？



Chinchilla尺度定律

- **幂律关系**：模型性能随三要素增长呈幂律提升，可预测且无明显天花板。
- **三要素同等重要**：性能受限于最短板要素，单点放大收益会迅速递减。
- **最优配比**：给定计算预算，存在最优的参数量与数据量配比。

$$N \propto C^{0.5}, D \propto C^{0.5}$$

在给定计算预算的条件下，参数量N与数据量D应等比例扩展，而非优先放大模型规模。

语言模型发展——预训练语言模型阶段

核心思想：用无标注数据预训练整个网络，微调后即可适配所有下游任务，大幅减少标注需求

预训练语言模型阶段虽然没有完全实现所有任务的统一，但确立了“**预训练+微调**”范式，并出现了**自回归建模**和**Scaling Law**，为下一阶段彻底摆脱标注依赖奠定了基础。

涌现


在 Scaling Law 的指导下，语言模型规模不断提升，当参数量突破某个阈值后，小规模模型无法获得的能力突然涌现出来。






语言模型发展——大语言模型阶段


核心思想：通过自回归语言建模在海量无标注数据上预训练，
用提示词替代微调，零样本完成所有任务。




闭源案例：GPT系列模型的技术演进



开源案例：关于LLaMA的研究工作



总结：语言建模的不同阶段






目录

- **第一节 大语言模型简介**
- **第二节 大语言模型的构建方法**
- **第三节 大语言模型的应用**



大语言模型的构建方法

大语言模型训练的常规流程



预训练奠定大语言模型（LLMs）能力的基础



预训练让模型从海量文本中学习语言知识和世界规律，为后续任务打基础。


预训练中的核心问题

数据准备




数据从哪来？怎么清洗？怎么组织？

模型架构



模型训练




第七章 大语言模型

数据准备——数据采集

- 从多种数据源收集大量自然语言语料（PB 级）

质量兼顾才是最好



数据准备——预处理

原始语料库



质量过滤

- 语种过滤
- 统计过滤
- 关键词过滤
- 分类器过滤

Alice is writing a paper about LLMs. #S^& Alice is writing a paper about LLMs.

敏感内容过滤

- 有毒内容
- 隐私内容 (PII)

替换('Alice') is writing a paper about LLMs.

数据去重

- 句子级别
- 文档级别
- 数据集级别


Alice is writing a paper about LLMs. Alice is writing a paper about LLMs.

词元化 (分词)

- BPE 分词
- WordPiece 分词
- Unigram 分词

编码(['Somebody'] is writing a paper about LLMs.)


准备预训练!



32, 145, 66, 79, 12, 56, ...


数据准备——数据调度

- 数据预处理完成后，还需设计合适的数据调度策略，包括：
 - **数据混合策略**：各数据源的比例配置
 - **数据课程规划**：各数据源参与训练的顺序安排




第七章 大语言模型

模型架构



Transformer Block


多层Transformer Block堆叠



纯解码器架构大语言模型


大语言模型基于 Transformer 架构，其优势在于并行计算高效、长距离依赖建模能力强、可扩展性极佳。

模型架构




编码器-解码器

编码器编码输入，解码器生成输出，适合序列转换任务。



纯解码器

仅用解码器，因果注意力，逐词生成。




前缀解码器

前缀部分双向注意力，生成部分因果注意力。

第七章 大语言模型

模型训练




$$\mathcal{L} = -\frac{1}{n} \sum_{i=1}^n \log P(w_i | w_1, \dots, w_{i-1})$$


其中, $w = \{w_1, \dots, w_n\}$ 表示一个序列

第七章 大语言模型


并行训练



流水线并行




张量并行



混合并行

第七章 大语言模型

数据并行



数据并行凭借其直观的原理和广泛的适用性，已成为分布式训练的主流解决方案。



模型并行


大语言模型的规模迅速增长，已超出单GPU内存的容量限制

模型名称	发布机构	总参数量
GPT-4	OpenAI	~1.8万亿
Gemini Ultra	Google	~1.6万亿
Claude 3 Opus	Anthropic	未知（估计千亿级）
GPT-3.5	OpenAI	1750亿
Llama 3 70B	Meta	700亿
DeepSeek-R1	深度求索	1410亿
Mixtral 8x7B	Mistral AI	467亿
Qwen2.5-MoE	阿里巴巴	约300亿
ChatGLM3	智谱AI	约130亿


解决方案：将网络参数拆分到不同的GPU上

模型并行


流水线并行: 按层分割



张量并行: 分割张量



模型推断



Time step	1	2	3	4
A	0.5	0.1	0.2	0.0
B	0.2	0.4	0.2	0.2
C	0.2	0.3	0.4	0.2
<eos>	0.1	0.2	0.2	0.6

词表

贪婪搜索

选择当前步骤中概率最高的令牌。

随机采样

基于采样的方法对整个词汇表中的标记进行采样

温度采样


调整 softmax 函数的温度系数以计算概率

$$P(x_j|\mathbf{x}_{<i}) = \frac{\exp(l_j/t)}{\sum_{j'} \exp(l_{j'}/t)}$$

Top-k/Top-p采样

仅从具有前k个最高概率的令牌中采样，或从累积概率高于（或等于）p的最小集合中采样

指令微调





第七章 大语言模型

为什么需要指令微调

预训练模型语言理解能力强，但常无法准确理解用户意图。



用户输入：“给我讲个笑话”



基础模型

讲个笑话。笑话是一种幽默形式，通常以简短的故事或对话呈现，目的是引人发笑。

VS

为什么数学书总是很忧伤？
因为它有太多问题。



指令微调
后的模型

第七章 大语言模型

什么是指令微调

- **目的：**使模型能够更准确地**解析和执行用户的指令**，提高其在**各种应用场景**下的实用性和可靠性。
- **操作：**用“指令-回答”数据对预训练模型进行有监督微调。



指令微调的关键：指令数据构造

- 指令数据构建的主要步骤
 - 指令生成
 - 指令筛选

指令数据构建——指令生成

➤ 常见指令生成方式:

- **人工书写。**由人类标注员根据需求，人工撰写指令-回答对。
- **利用互联网社区问答数据。**从公开的互联网平台收集用户提出的问题 and 高质量回答。
- **利用AI模型。**利用已有的强大语言模型（如GPT-4、Claude）生成高质量指令-回答对。



第七章 大语言模型

指令数据构建——指令筛选

- 从大量指令数据中筛选出高质量数据
 - **利用LLM做筛选（专用打分模型）**：用GPT-4等模型对数据评分，精度最高但成本高。
 - **利用指令数据统计信息做筛选**：基于长度、困惑度等指标设阈值过滤，成本极低但只能剔除明显低质数据。
 - **利用打标签去做筛选**：标注任务类型、难度、安全性等维度，实现精细化数据配比。

指令数据构建——指导性原则

➤ 数据量

- 专项模型适配单个任务数千条即可达到不错效果；通用模型通常需要数十万条或更多

➤ 覆盖种类

- 数学、代码、推理、闲聊、智能体、多语言、安全等

➤ 单独科目的加强

- 数学、代码通常需要更多的数据和策略来实现效果增强

➤ 数据合成与筛选

- 质量和多样性比数量更重要，可通过筛选过滤低质量数据




第七章 大语言模型

当前指令数据集丰富

Dataset	#Tasks	# Instructions	Language	Collection Method	Usage	Access	Human Verified?
xP3 (Muennighoff et al., 2022)	83	-	Multilingual	Mixed	Instruct. Tuning	Open	No
Super-Natural-Instructions (v2) (Wang et al., 2022b)	1,616	1,616	Multilingual				
ZeroPrompt (Xu et al., 2022)	1,110	-	Chinese				
GLM-130B (Zeng et al., 2023)	74	-	Multilingual (eng, zh)				
gCLUE (CLUEbenchmark, 2021)	9	73	Chinese				
Belle-1.5M (Yunpie et al., 2023)	175	1.5M	Chinese				
Guanaco-Dataset (JosephusCheung, 2021)	175	534,530	Multilingual				
CSL (Li et al., 2022)	4	396,209	Chinese				
Chinese-ChatLLaMA (YDli-ai, 2021)	-	-	Multilingual				
Purely (Yang, 2023)	23	1.1M	Chinese				
Lunao (Zhang Leng and Li, 2023)	175	51,672	Chinese				
Chinese-Alpaca (Liu et al., 2023)	-	-	Chinese				
GPT-4-LLM (Peng et al., 2023)	175	165K	Multilingual (eng, zh)				
ShareGPT (ShareGPT, 2021)	-	-	Multilingual				
Chinese-Vicuna (Chenghao Fan and Tian, 2023)	-	1M	Chinese				
CUGB (Yao et al., 2021)	18	-	Chinese				
HC3 (Guo et al., 2023)	12	37,175	Multilingual (eng, zh)				
InstructWild (Xue et al., 2023)	429	104K	Multilingual (eng, zh)				
Our Translated Corpus	2k	67,798	Chinese				

Dataset	# Tasks	# Instructions	Lan	Collection Method	Usage	Access	Verified?
PromptSource (Bach et al., 2022)	180	2,085	English	Mixed	Instruct.	Open	Yes
P3 (Sanh et al., 2021)							
xP3 (Muennighoff et al., 2022)							
OpenAI (AI, 2021)	30	43M	English	Mixed	Instruct. Tuning	Open	No
Baize (Xu et al., 2023)	3	100K+	English	Model Generated	Chat	Open	No
Camel (Guohao et al., 2023)	-	115K	English	Model Generated	Instruct. Tuning, Chat	Open	No
UltraChat (Ding et al., 2023)	-	675K	English	Model Generated	Chat	Open	No
Dolly (Databricks, 2022)	7	15,000	English	Human Annotated	Instruct. Tuning	Open	Yes
Guanaco-Dataset (JosephusCheung, 2021)	175	534,530	Multilingual	Mixed	Instruct. Tuning	Open	No
ChatLLaMA Chinese-ChatLLaMA (YDli-ai, 2021)	-	-	Multilingual	Mixed	Instruct. Tuning	Open	No
GPT-4-LLM (Peng et al., 2023)	175	165K	Multilingual	Model Generated	RLHF, Instruct. Tuning	Open	No
ShareGPT (ShareGPT, 2021)	-	-	Multilingual	Model Generated	Instruct. Tuning, Chat	Closed	Yes
SHP (Ethayarajah et al., 2023)	18	385K	English	Existing, Human Annotated	RLHF, Instruct. Tuning	Open	Yes
HH-RLHF (Bai et al., 2022; Anthropic, 2022; Ganguli et al., 2022)	-	169,550	English	Mixed	RLHF, Instruct. Tuning	Open	Yes
HC3 (Guo et al., 2023)	12	37,175	Multilingual	Mixed	Instruct. Tuning	Open	Yes
Stack-Exchange-Preferences (Lambert et al., 2023)	-	10M	English	Existing	RLHF, Instruct. Tuning	Open	Yes
InstructWild (Xue et al., 2023)	429	104K	Multilingual	Model Generated	Instruct. Tuning	Open	No

监督微调





全量微调的挑战

- 全量微调存在的问题
 - 训练成本较高，微调的参数量跟预训练一样
 - 灾难性遗忘

全量微调

Method	Bits	7B	14B	30B	70B
Full (bf16 or fp16)	32	120GB	240GB	600GB	1200GB
Full (pure_bf16)	16	60GB	120GB	300GB	600GB
Freeze/LoRA/GaLore/APOLLO/BAdam/OFT	16	16GB	32GB	64GB	160GB
QLoRA / QOFT	8	10GB	20GB	40GB	80GB
QLoRA / QOFT	4	6GB	12GB	24GB	48GB
QLoRA / QOFT	2	4GB	8GB	16GB	24GB

高效微调

高效微调 (PEFT)


➤ 典型方法

- Adapter Tuning(Google, 2019)
- Prefix Tuning(Stanford, 2021)
- LORA(Microsoft, 2021)

第七章 大语言模型


高效微调——Adapter Tuning

- **核心思想**：在Transformer层中插入小型可训练Adapter模块，仅更新这些模块。
- **特点**：
 - 结构简单，易于插入和切换
 - 推理时会引入额外计算开销



高效微调——Prefix Tuning


- **核心思想**：在输入序列前添加一组可训练的前缀，引导模型生成。
- **特点**：
 - 不改变模型结构，推理时前缀可预计算
 - 占用部分输入长度，影响有效上下文窗



第七章 大语言模型

高效微调——LoRA

- **核心思想**：在权重矩阵旁路添加低秩分解矩阵，通过优化低秩矩阵实现参数更新。
- **特点**：
 - 无推理延迟，效果接近全量微调
 - 存储成本低
 - 目前应用最广泛的高效微调方法



偏好对齐



为什么要进行偏好对齐

指令微调让模型学会“回答问题”，但未必学会“回答得好、符合人类偏好”。



用户输入：我失恋了，怎么办？



指令微调
后的模型

失恋后的建议：1.接受现实
2.转移注意力 3.寻求社交支持
4.给自己时间.....

机械、冰冷

VS



偏好对齐
后的模型

失恋真的很难受，我理解你现在的痛苦。给自己一点时间难过没关系，但别忘了照顾好自己....

共情、温暖

第七章 大语言模型

为什么要进行偏好对齐——3H 法则 一个优秀的大语言模型应该满足3H法则

➤ 有益性 (Helpfulness)


AI应帮助用户完成其任务

➤ 真实性 (Honesty)

AI应提供准确的信息

➤ 无害性 (Harmlessness)

AI不应给人类或环境造成身体、心理
或社会层面的伤害



人工智能欺骗示例：研究人员发现，GPT-4在模拟场景中从事隐蔽的非法内幕交易。尽管用户明确禁止内幕交易，但同时强调AI系统必须实现盈利交易，导致AI系统选择隐藏其交易行为。

什么是偏好对齐

目的：使模型的输出**更符合人类偏好**，在**有用性、诚实性、无害性**等维度上**对齐人类价值观**，提升交互体验。

操作：用“**指令-好回答-差回答**”的**偏好对比数据**，通过对比学习或强化学习（如RLHF、DPO）训练模型学习回答的优劣差异。




第七章 大语言模型

偏好对齐的主要步骤——以RLHF为例

第一步： 指令微调

第二步： 收集对比数据，并
训练奖励模型

第三步： 使用强化学习方法，
基于奖励模型优化策略



第七章 大语言模型

收集对比数据

➤ 输入提示

向指令微调后的模型输入一批提示 (prompts)


➤ 生成多个输出

每个提示由模型生成K个候选回答

➤ 人类标注员排序

标注员对同一提示下的K个输出进行排序，选出更符合人类偏好的回答

“我考试考砸了，好难过，怎么办？”



指令微调后的模型



A. 多喝热水

B. 别难过了，下次努力就好。

C.你真是个废物，这点小事都做不好。

D.我建议你去吃顿好的，然后睡一觉，明天重新开始。



D>B>A>C

第七章 大语言模型

训练奖励模型

➤ 奖励模型架构

输入：提示词和回复


结构：以SFT模型的Transformer主体为基础，移除输出端的最后一层，替换为投影层。

输出：单个标量分数。

➤ 优化目标：

$$\text{loss}(\theta) = -\frac{1}{\binom{K}{2}} E_{(x, y_w, y_l) \sim D} [\log(\sigma(r_\theta(x, y_w) - r_\theta(x, y_l)))]$$

更好回复的奖励 更差回复的奖励



其中， r_θ 为待优化的奖励模型， x 为提示词， y_w 为较优回答， y_l 为较劣回答。


第七章 大语言模型

什么是强化学习

强化学习是一种**智能体通过与环境交互，根据环境反馈的奖励信号来学习最优策略**的机器学习方法。

➤ 强化学习的核心要素

- **智能体**：做决策的模型，即要训练的对象
- **环境**：智能体交互的外部系统
- **状态**：当前时刻环境的描述
- **动作**：智能体采取的行为
- **奖励**：环境对动作的即时反馈




第七章 大语言模型

什么是强化学习

强化学习是一种智能体通过与环境交互，根据环境反馈的奖励信号来学习最优策略的机器学习方法。

➤ 智能体与环境的交互

- 智能体观察当前状态
- 智能体根据当前策略选择动作
- 环境执行动作，更新状态，**返回奖励**
- 智能体根据奖励信号调整策略
- 循环往复，不断优化



第七章 大语言模型

将偏好对齐建模为强化学习问题

- 智能体 (Agent) : SFT后的大语言模型, 是要训练的目标模型, 负责生成回答。
- 环境 (Environment) : 文本生成的**外部系统**, 包括词表、停止规则、奖励模型等。
- 状态 (State, S_t) : 提示词加已生成的tokens, 即当前已生成的全部文本。
- 动作 (Action, A_t) : 生成下一个token, 从词表中选择一个token。
- 奖励 (Reward, R_{t+1}) : Reward Model给出的分数, 衡量回答是否符合人类偏好。

第七章 大语言模型

将偏好对齐建模为强化学习问题

➤ PPO目标函数：

$$E_{(x,y) \sim D_{\pi_{\phi}^{RL}}} \left[\underbrace{r_{\theta}(x, y)}_{\text{奖励模型给的奖励}} - \underbrace{\beta \log \frac{\pi_{\phi}^{RL}(y|x)}{\pi^{SFT}(y|x)}}_{\text{KL散度约束actor模型不偏离固定的SFT模型（也叫参考模型）。}} \right] + \gamma E_{x \sim D_{\text{pretrain}}} [\log(\pi_{\phi}^{RL}(x))] \quad \text{保持预训练阶段的语言能力}$$

PPO涉及到三个模型：Actor、奖励模型、参考模型。

注：这里的PPO指的是InstructGPT论文中的PPO，下文提到的PPO都是这个意思。



大语言模型的应用




提示词工程

第七章 大语言模型


在NLP研究语境中提示词（prompt）是什么？

直观定义：提示词是给语言模型的一个线索，使其能更好地理解人类的问题。



第七章 大语言模型

在NLP研究语境中提示词（prompt）是什么？



大模型时代，无需微调与特定任务设计，仅凭提示词就能胜任多数语言任务。

第七章 大语言模型

提示词的要素

- **指令**：想要模型执行的特定任务或指令。
- **上下文**：包含外部信息或额外的上下文信息，引导语言模型更好地响应。
- **输入数据**：用户输入的内容或问题。
- **输出指示**：指定输出的类型或格式。

一个样例

指令：帮我分类输入数据的情感并总结要点

上下文（示例）：

输入：质量很好，非常满意

输出：{ “情感”： “正面”， “摘要”： “产品质量好” }

输入数据：到货快，包装严实，但屏幕有划痕，客服处理及时，整体还行

输出指示：JSON格式，包含“情感”和“摘要”两个字段



设计提示的通用技巧

1. **从简单开始**: 从简单提示起步，迭代优化。
2. **指令明确**: 用“翻译”“总结”等命令词，可用“###”分隔指令与内容。
3. **具体详细**: 提示越具体，结果越好。
4. **避免模糊**: 直接、简洁，不说废话。
5. **说要做什么**: 不要告诉模型“不要做什么”，直接说“要做什么”。
6. **分解复杂任务**: 把大任务拆成小任务，逐步完成。



提示技术——翻译任务

把下面这段英文翻译成中文：

Spending lots of time thinking about different possible future scenarios and their probabilities might be captivating, but I suggest an absolutely different approach — to try to build your prototype yourself. First, it' s rather challenging and fun. Second, it will help us to look at our work in a more structured way. Third, it will give us an opportunity to try in practice one of the most cutting-edge approaches — LLM agents.

第七章 大语言模型

提示技术——少样本提示

回答:

花很多时间思考各种可能的未来场景及其概率可能很吸引人，但我建议一种完全不同的方法——尝试自己构建你的原型。首先，这相当具有挑战性和趣味性。其次，它将帮助我们以更结构化的方式看待我们的工作。第三，它将给我们一个机会在实践中尝试最前沿的方法之一——LLM智能体。

第七章 大语言模型

提示技术——角色

把下面这段英文翻译成中文：

你是一个擅长中文和英文的AI工程师和数据科学家，擅长中文和英文相关的AI技术文章编写和翻译。把下面这段英文翻译成中文：

Spending lots of time thinking about different possible future scenarios and their probabilities might be captivating, but I suggest an absolutely different approach — to try to build your prototype yourself. First, it' s rather challenging and fun. Second, it will help us to look at our work in a more structured way. Third, it will give us an opportunity to try in practice one of the most cutting-edge approaches — LLM agents.

提示技术——少样本提示

回答:

与其花大量时间琢磨各种未来走向及其概率，不如换个思路——自己动手把原型做出来。一来，这个过程本身就充满挑战和乐趣；二来，能让我们的工作更有章法；三来，还能亲身实践当下最前沿的技术方向——LLM智能体。

第七章 大语言模型

提示技术——链式思考 (CoT) 提示

你是一个擅长中文和英文的AI工程师和数据科学家，擅长中文和英文相关的AI技术文章编写和翻译。
请将下面的英文翻译成中文，要求语言生动活泼，简洁优雅。

你需要两个步骤来执行这个任务：

1. 将英文直接翻译为中文，主要考虑意思表达的准确性
2. 将步骤 1 直译的中文翻译成更简洁优雅通顺的中文标题，主要考虑中文的语言表达习惯

需要翻译的英文文章标题：

Spending lots of time thinking about different possible future scenarios and their probabilities might be captivating, but I suggest an absolutely different approach — to try to build your prototype yourself. First, it's rather challenging and fun. Second, it will help us to look at our work in a more structured way. Third, it will give us an opportunity to try in practice one of the most cutting-edge approaches — LLM agents.

第七章 大语言模型

提示技术——链式思考 (CoT) 提示

步骤1翻译结果:

花大量时间思考各种可能的未来情景及其概率可能很吸引人，但我建议一种完全不同的方法——尝试自己动手构建你的原型。首先，这相当具有挑战性且有趣。其次，这将帮助我们用更结构化的方式审视我们的工作。第三，这将给我们一个机会在实践中尝试最前沿的方法之一——LLM智能体。

步骤2翻译结果:

与其花时间畅想未来的各种可能，不如亲自上手做个原型。一来，这本身就充满挑战 and 乐趣；二来，能让我们的工作思路更清晰；三来，还能亲身体验当下最前沿的技术——LLM智能体。

第七章 大语言模型

提示技术——自我一致性

你是一个擅长中文和英文的AI工程师和数据科学家，擅长中文和英文相关的AI技术文章编写和翻译。请将下面的英文翻译成中文，要求语言生动活泼，简洁优雅。

为了确保翻译质量，**请独立翻译三次**。每次翻译都按照以下两步结构输出：

- 1.直译（准确性优先）
- 2.优化（简洁优雅优先）

最后，从三次翻译的优化版本中选出最优的一个，并说明理由。

需要翻译的英文：

Spending lots of time thinking about different possible future scenarios and their probabilities might be captivating, but I suggest an absolutely different approach — to try to build your prototype yourself. First, it's rather challenging and fun. Second, it will help us to look at our work in a more structured way. Third, it will give us an opportunity to try in practice one of the most cutting-edge approaches — LLM agents.

第七章 大语言模型

提示技术——自我一致性

第一次翻译

步骤1 直译：

花大量时间思考各种可能的未来情景及其概率可能很吸引人.....

步骤2 优化：

与其花时间畅想未来的各种可能，不如亲自上手做个原型.....

第二次翻译

步骤1 直译：

花费大量时间去思考各种未来可能的情景及其发生概率.....

步骤2 优化：

与其花大量时间琢磨各种未来走向的概率.....

第三次翻译.....

第七章 大语言模型

提示技术——自我一致性

最优选择

选择：第一次翻译的优化版本

理由：

“畅想”比“琢磨”“盘算”更贴合原文“captivating”的意境，既有画面感又不过于口语化

“一来二来三来”的排比结构节奏感最强，读起来朗朗上口

“工作思路更清晰”比“工作更有条理”“工作更有章法”更自然，符合技术文章的表达习惯

整体在专业性和口语化之间平衡得最好，既简洁优雅又不失准确

第七章 大语言模型

提示技术——生成知识提示

输入：为什么大模型会出现幻觉？

知识：大模型本质是“下一个词预测”系统，它根据概率生成最可能的词，并不理解内容的真实性。当训练数据中有错误信息，或者模型遇到知识盲区时，它会“编造”看似合理的内容来维持流畅性。

回答：大模型出现幻觉的根本原因是：它只追求“像人类写的”，不追求“符合事实”。

输入：为什么RLHF可以让模型输出更安全？

知识：RLHF（基于人类反馈的强化学习）通过让人类标注员对模型的多条输出进行排序，再用这些偏好数据训练奖励模型，最终通过强化学习让模型倾向于生成人类偏好的内容。安全类回答在训练中被赋予高奖励。

回答：RLHF通过人类反馈构建奖励信号，让模型学会“什么样的回答更安全”，从而减少有害输出。

输入：为什么RAG可以缓解大模型幻觉？

知识：

回答：

第七章 大语言模型

提示技术——生成知识提示

知识：大模型的幻觉源于其生成过程完全依赖参数化记忆（训练数据中学到的知识）。当遇到训练数据未覆盖、记忆模糊或存在错误的信息时，模型会基于概率“编造”内容。

RAG（检索增强生成）在生成前先从外部知识库检索相关文档，将检索结果作为上下文输入模型。模型基于这些证据生成回答，而非仅凭内部记忆。

回答：RAG通过“先检索后生成”的机制，让模型的回答有据可依，不再依赖不可靠的内部记忆，因此能有效缓解幻觉。

以少样本提示，激发大模型先生成知识，再根据知识回答问题。

第七章 大语言模型

提示技术——链式提示

提示词：

我需要设计一份关于“大学生短视频使用情况”的调查问卷。请先帮我确定问卷应该涵盖哪些调查维度，每个维度下包含哪些具体方面。

回答：

维度1：**使用行为**，包含使用频率、使用时长、使用时段、常用平台。维度2：**内容偏好**，包含常看内容类型、关注账号数量及类型、主动搜索还是被动刷推荐。维度3：**使用动机**，包含主要目的、情绪驱动。维度4：**影响感知**，包含对学习的影响、对睡眠的影响、对社交的影响、自我控制评价。

第七章 大语言模型

提示技术——链式提示

将复杂任务拆解为多个步骤，每一步基于上一步的结果继续推进

提示词：

我需要设计一份关于“大学生短视频使用情况”的调查问卷。请先帮我确定问卷应该涵盖哪些调查维度，每个维度下包含哪些具体方面。

回答：

维度1： **使用行为**，包含使用频率、使用时长、使用时段、常用平台。维度2： **内容偏好**，包含常看内容类型、关注账号数量及类型、主动搜索还是被动刷推荐。维度3： **使用动机**，包含主要目的、情绪驱动。维度4： **影响感知**，包含对学习的影响、对睡眠的影响、对社交的影响、自我控制评价。

第七章 大语言模型

提示技术——链式提示

将复杂任务拆解为多个步骤，每一步基于上一步的结果继续推进

提示词：

为“**使用行为**”部分生成3-5道具体的问卷题目，每题包括题干和选项。维度内容：使用频率、使用时长、使用时段、常用平台。

回答：

第1题：你平均每天刷短视频的频率是？ A. 1-2次 B. 3-5次 C. 6-10次 D. 10次以上。

第2题：你平均每次刷短视频的时长是？ A. 10分钟以内 B. 10-30分钟 C. 30-60分钟 D. 1-2小时 E. 2小时以上.....

第七章 大语言模型

提示技术——链式提示

将复杂任务拆解为多个步骤，每一步基于上一步的结果继续推进

提示词：

请继续为“使用动机”和“影响感知”两个维度生成题目，每个维度3-5题。


回答：

使用动机部分： 第5题：你刷短视频最主要的原因是？ A. 打发空闲时间 B. 获取信息/知识 C. 娱乐放松 D. 跟风/社交需要 E. 习惯性打开。第6题：你觉得自己刷短视频更多是主动选择，还是被动滑动？ A. 主要是主动搜索想看的内容 B. 主要是刷推荐页，被动接收 C. 两者差不多。影响感知部分： 第7题：你认为刷短视频对你的学习效率有何影响.....

第七章 大语言模型

提示技术——思维树 (ToT)


核心思想：将复杂问题分解为多个中间步骤，在每个步骤生成多个候选思维，通过评估和搜索算法探索最优路径，必要时回溯重新选择。



第七章 大语言模型

提示技术——检索增强生成 (RAG)

核心思想：先从外部知识库检索相关文档，再将这些文档作为上下文与用户问题一起输入给语言模型，生成更准确、可靠的答案。





Vibe Coding

第七章 大语言模型

氛围编程 (Vibe Coding)

Vibe Coding (氛围编程) 是一种以 AI 为协作伙伴，通过自然语言描述需求，由大型语言模型自动生成代码，开发者关注运行结果而非逐行理解代码的编程方式。



第七章 大语言模型

氛围编程——核心原则

➤ 意图驱动编程

不再需要深入了解具体的代码实现，只需要清楚地表达你想要什么，AI 会帮你实现

➤ 沉浸式体验

完全沉浸在创造的过程中，减少与具体技术细节的交互摩擦

➤ 指数级效率

通过AI的协助，开发效率可以实现指数级的提升

➤ 创意优先

将更多精力投入到产品设计和用户体验，而非底层代码实现

第七章 大语言模型

氛围编程——常用工具

- Cursor: AI原生编辑器, 直接对话生成代码
- Windsurf: 类似Cursor, 强调AI协同体验
- Trae: 字节跳动出品, AI原生IDE, 国内友好
- GitHub Copilot: 代码自动补全插件
- Cline: VS Code插件, 可执行命令、读写文件
- Claude Code: Anthropic的终端AI编程助手
- ChatGPT / Claude: 直接对话生成代码

第七章 大语言模型

MCP——AI的“万能转接头”

➤ 什么是MCP?

MCP是Anthropic推出的开放协议，让AI模型能以统一方式连接外部工具和数据源。就像USB-C接口一样，一个标准连接所有设备。

➤ 为什么需要MCP?

传统方式下，让AI调用工具需要针对不同平台重复开发，且敏感数据必须上传云端。MCP统一了接口标准，数据留在本地，一次开发到处可用。

➤ 工作流程

用户提问 → AI决定调用哪个工具 → 执行对应MCP Server → 返回结果
→ AI生成回答

第七章 大语言模型

案例：使用Trae构建一个天气查询工具

- 定义多个专用智能体，为其配备合适的MCP工具，组建编程团队。
- Trae社区中，有别人定义好的专用智能体，可以直接导入。






第七章 大语言模型

案例：使用Trae构建一个天气查询工具

请帮我构建一个天气查询工具，使用开源 API。具体流程如下：首先，由产品经理分析需求；接着，架构师根据产品经理和需求分析的结果，设计整体技术框架；然后，UI/UX 设计师完成前端界面设计；之后，前端工程师与后端工程师分别进行功能实现；最后，质量监督员进行测试，并提出改进意见。







第七章 大语言模型

案例：使用Trae构建一个天气查询工具

将任务分解，创建待办，多智能体开始协同工作。



案例：使用Trae构建一个天气查询工具



总结

➤ 核心技术

自回归：预测下一个词。

尺度定律：参数量、数据量、计算量越大，效果越好，且三者要等比例扩展。

涌现：参数规模突破某个阈值后，小模型不具备的能力突然出现。

➤ 构建三阶段

预训练：在海量文本上学习语言规律和世界知识。

指令微调：用“指令-回答”对训练，让模型听懂人话。

偏好对齐：用“好回答-差回答”对训练，让模型说得更好。

总结

➤ 高效微调

LoRA: 在权重旁加低秩矩阵, 目前应用最广。

Prompt Tuning: 在输入嵌入层加可训练的软提示。

Adapter Tuning: 在Transformer层中插入小模块。

➤ 偏好对齐方法

RLHF: 训练奖励模型, 再用PPO强化学习优化。

DPO: 直接优化, 无需奖励模型, 更简单。

GRPO: 分组采样, 组内归一化, 省掉价值模型。