



南京航空航天大学
NANJING UNIVERSITY OF AERONAUTICS AND ASTRONAUTICS

人工智能内容生成 (AIGC) 技术与应用



一周AI要闻 (3.30-4.05)

极佳视界世界模型GigaWorld-1震撼登场，超越谷歌、英伟达

WorldArena Leaderboard

A unified leaderboard for evaluating perception in the observability of frontier AI models.

Model	F1 Score	Form	Visual Quality	Motion Quality	Content Consistency	Physics Adherence	3D Accuracy	Controllability
GigaWorld-1	85.74	5	93.84	93.75	93.77	94.09	97.05	97.08
DiffWorld	85.08	5	97.45	93.82	93.95	93.87	96.46	93.82
World-0	85.00	5	92.81	91.90	94.00	93.97	94.99	93.83
Diffusion	84.76	5	93.79	93.18	93.11	93.99	96.28	96.09
Altos_PhysWorld	84.47	5	90.85	90.90	93.98	93.98	96.36	96.00
World-1	87.21	5	97.49	93.36	94.34	94.99	96.96	92.15
Diffusion	86.14	7	95.14	93.32	93.74	93.34	96.01	93.82
NovelAI	84.82	5	98.80	94.90	93.80	93.34	95.36	93.81
World	83.42	5	92.16	93.27	94.39	92.82	95.28	94.70
Common Predict (3.5.0.0)	84.26	10	90.93	91.30	91.73	92.86	97.32	96.07

人大林衍凯教授：OpenClaw就像早期Linux

OpenClaw做了什么	OpenClaw没做什么
IM接入	预训练
Skill生态	RL训练
分层记忆	工具学习
Gateway标准化	推理优化

OpenClaw之于大模型 = 浏览器之于互联网®

——它不创造内容，但定义了交互方式

全网疯传fork! Claude Code源代码泄露被开源了




美团发布LongCat-Next：把图像、声音、文字都变成Token



疯狂的Skill:前任、老板、同事...全部token化!



GPT-Image-2流出, Nano Banana Pro要被拉下神坛?



自回归语言建模

学生们打开了他们的——

- 书
- 笔记本电脑
- 试卷
- 心扉



自回归语言建模

➤ 优化目标:

$$\mathcal{L} = -\frac{1}{n} \sum_{i=1}^n \log P(w_i | w_1, \dots, w_{i-1})$$

其中, $w = \{w_1, \dots, w_n\}$ 表示一个序列

自回归建模方式为统一所有NLP任务提供了可能。


尺度定律

- **幂律关系**：模型性能随三要素增长呈幂律提升，可预测且无明显天花板。
- **三要素同等重要**：性能受限于最短板的要素，单点放大收益会迅速递减。
- **最优配比**：给定计算预算，存在最优的参数量与数据量配比。


$$N \propto C^{0.5}, D \propto C^{0.5}$$

涌现

在尺度定律的指导下，语言模型规模不断提升，当参数量突破某个阈值后，小规模模型无法获得的能力突然涌现出来。



大语言模型训练的常规流程



文本续写能力

回答问题能力

更好地回答用户

大语言模型应用

- 提示词工程
 - 少样本提示
 - 链式思考
 - 自我一致性校验
 - 链式提示等
- 氛围编程

仅凭文本，能解决所有现实问题吗？

任务：描述这个图片的内容

仅仅是描述图片这个简单的问题，仅靠理解文本就无法完成



第八章

多模态大模型

目录

- 多模态大模型简介
- 多模态大模型发展历程
- LLaMA家族

多模态大模型简介


第八章 多模态大模型

什么是多模态

➤ 多模态 (Multimodality)

指的是使用多种不同类型的数据或信息通道


(模态) 来表示和处理信息。人类天生就是多模态的生物，我们通过视觉、听觉、触觉、嗅觉和味觉感知和理解世界。




第八章 多模态大模型

现实世界充满了多模态的信息

- 多模态信号举例：视觉、触觉、嗅觉、听觉、语言、图像、音频、**雷达数据**，视频、图、时序等。




现实世界的任务需要AI能够理解多模态信息



自动驾驶系统

在此应用中，车辆结合使用**视觉数据（摄像头）、空间数据（激光雷达）和听觉信号（声呐）**来安全导航



医疗诊断

医学影像工具如核磁共振、CT扫描和X光，连同患者病史和口述症状，共同用于疾病诊断。



智能家居助手


像亚马逊 Alexa 和谷歌家庭助手这类设备，通过**语音指令（音频）、物理交互（触摸）**，有时还包括**视觉提示**来运行。

大语言模型有“理解”，但缺“多模态”

可以让大语言模型感知并理解多模态信息吗？

大语言模型的优势	大语言劣势
强大的理解与推理能力  语言理解、逻辑推理、知识记忆、文本生成	无法直接感知多模态信息  图像、视频、音频、传感器数据

多模态大模型




多模态大语言模型（MLLM）是以**大语言模型为核心认知与推理引擎**，通过引入额外的**模态编码器与连接模块**，实现对图像、视频、音频等多模态信息的感知、融合与生成的一类模型。

第八章 多模态大模型

多模态大模型的基本架构


➤ 多模态大模型的核心：

- **模态编码器**：将不同形态的输入转换为模型可处理的统一特征向量。
- **连接器**：将非文本特征对齐并映射到语言模型的理解空间，实现跨模态语义融合。
- **大语言模型核心**：作为统一的“大脑”，对融合后的跨模态信息进行深度理解和推理。
- **模态生成器**：将语言模型的理解结果转换成对应的文本、音频或图像等输出形式。






多模态大模型



多模态大模型发展阶段




第八章 多模态大模型

早期探索 (2017-2020) —— 多模态融合的起点

核心思想：通过双流架构和对比学习（如CLIP），实现了视觉与语言的初步融合和对齐。

➤ 代表性工作：


- 对比学习突破：CLIP (2021年初)



CLIP: 通过自然语言监督学习可迁移视觉模型

➤ 核心架构:

双编码器架构: 一个编码器处理图像,
一个编码器处理文字, 通过对比学习
让匹配的图文在嵌入空间中更接近。




第八章 多模态大模型

图像编码器：ViT

➤ 图像分块与展平


- ① 将图像 $x \in \mathbb{R}^{H \times W \times C}$ 切成 N 个大小为 $P \times P$ 的块, $N = (H \times W)/P^2$
- ② 每个块展平为向量 $x_p \in \mathbb{R}^{P^2 \times C}$



第八章 多模态大模型

图像编码器：ViT

- 线性投影
- 使用可训练的线性层（全连接层）将每个块向量映射到固定的维度 D
- 输出： N 个 D 维的嵌入向量，相当于NLP中的词嵌入




第八章 多模态大模型

图像编码器：ViT

- 添加位置编码
- Transformer本身不包含位置信息，需要显式加入位置编码。
- ViT使用可学习的1D位置编码形状为 $(N + 1) \times D$ 。


加了一个特殊标记向量



第八章 多模态大模型

图像编码器：ViT

- 分类头标记
 - 借鉴BERT，在序列开头加入一个**可学习的 [CLS] 标记**。
 - 经过Transformer后，该位置的最终输出向量（[CLS] 对应位置）被视为整张图像的聚合特征。






图像编码器：ViT

模型变体	层数 (L)	隐藏维度 (D)	MLP尺寸	头数	参数量
ViT-Tiny	12	192	768	3	5.7M
ViT-Small	12	384	1536	6	22M
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M

文本编码器：Transformer


CLIP的文本编码器是基于因果注意力掩码的标准Transformer解码器，它以[EOS]标记的输出作为整句话的语义特征向量。



CLIP: 通过自然语言监督学习可迁移视觉模型

➤ 训练任务


CLIP采用对比学习，用二分类交叉熵损失训练模型判断图文是否匹配。



第八章 多模态大模型

CLIP: 通过自然语言监督学习可迁移视觉模型

- CLIP将**零样本分类**视为图文匹配问题, 无需任何下游数据集训练。
- CLIP 无需下游微调, 是首个在图像领域实现高性能零样本的模型。



将图片与各个类别的文本计算相似度, 取相似度最高的类别作为预测结果。

第八章 多模态大模型

早期探索（2017-2020）——多模态融合的起点

核心价值：建立视觉与语言的语义对齐能力，为后续LLM接入多模态奠定基础。

➤ 这个时期做到了什么

证明跨模态联合表征可行，视觉与语言在表征层面能对齐交互。

➤ 这个时期没做到什么

缺乏统一认知中枢，仍是任务导向的专用模型，且不具备生成能力。




第八章 多模态大模型

LLM驱动的范式革命（2022-2023）—— 让LLM “睁开眼”

核心思想：以LLM为大脑，通过指令微调集成视觉能力，让模型能理解图像并遵循指令执行任务。

➤ 代表性工作


- 指令微调模型：LLaVA（2023）
- 视觉接入模型：BLIP-2（2023）
- 闭源突破：GPT-4V（2023）




第八章 多模态大模型

LLaVA: Large Language and Vision Assistant

核心架构：用一个简单的线性投影层
将图像特征直接映射到 LLM 的输入空间，
不做任何特征筛选，让 LLM 端到
端地学习视觉-语言对齐。



LLaVA: Large Language and Vision Assistant



➤ 两阶段训练

<https://github.com/haotian-liu/llava>

- 第一阶段：特征对齐预训练。基于图文对数据集，仅更新投影矩阵
- 第二阶段：端到端微调。同步更新投影矩阵与大语言模型（LLM）
 - 视觉对话（Visual Chat）：日常用户场景生成的多模态指令数据集。
 - 科学问答（Science QA）：面向科学领域的多模态推理数据集

第八章 多模态大模型



LLa

Visual input example, Extreme Ironing:

ant



Source: <https://www.barnorama.com/wp-content/uploads/2016/12/03-Confusing-Pictures.jpg>

User

What is unusual about this image?

LLaVA

The unusual aspect of this image is a man ironing clothes on the back of a minivan or van. This is not a typical place to perform this activity, as one would usually iron clothes in a more stationary and safe location, such as a home, using a regular ironing board. The scene depicted in the image is peculiar as it involves a makeshift ironing setup on a vehicle, which can be both unsafe and unconventional. Additionally, it is not clear how the man is able to maintain balance and stability while ironing clothes in such an unstable environment.

[Start a new conversation, and clear the history]

User

What's happening in the scene?

LLaVA

The image depicts a man standing on top of a yellow SUV in a busy city street. He is holding a portable ladder, seemingly ironing clothes while standing on the vehicle. Around the scene, there are other cars, a traffic light, and a fire hydrant. Additionally, there are two other people in the vicinity, one close to the man on the car and another further away. The man on the ladder appears to be attracting attention **due to his unconventional choice of ironing his clothes on top of a moving car**. The city street around him is bustling with activity, adding to the unique nature of the scene.

User


What is unusual about this image?

GPT-4 [32]

The unusual thing about this image is that a man is ironing clothes on an ironing board attached to the roof of a moving taxi.

BLIP-2

BLIP-2 训练 **Q-Former** 从冻结图像编码器提取视觉特征，再与用户文本指令拼接后输入冻结 LLM，使 LLM 理解图像并遵循指令，实现灵活的图像到文本生成。




第八章 多模态大模型


BLIP-2——Q-Former

➤ 多任务联合优化Q-Former

- ITC: 拉近匹配的图文对, 推远不匹配的。
- ITM: 判断图文是否匹配, 学习细粒度对齐。
- ITG: 强迫Q-Former提取足够信息, 让模型只看图像就能生成对应文本。



BLIP-2



➤ BLIP-2第二阶段训练:

冻结LLM，只训练Q-Former，将视觉特征作为前缀与文本拼接后输入LLM，通过标准的自回归语言建模损失来训练模型生成文本。

第八章 多模态大模型


BLIP-2

➤ 优势

BLIP-2 提出的 Q-Former 自动提取与文本最对齐的视觉特征，精准筛选、压缩冗余，降低 LLM 跨模态学习难度，**后常被用于多模态大模型中作为视觉与语言之间的高效桥接模块。**

➤ 缺点

压缩冗余的同时也丢失了一部分有价值的视觉信息，性能天花板受限。



第八章 多模态大模型

LLM驱动范式革命（2021-2023）—— 让LLM “睁开眼”

核心价值：将多模态能力从“判别”升级为“理解+生成”，确立了LLM作为多模态认知中枢的范式。

➤ 这个时期做到了什么

以LLM为认知中枢，首次实现开放域视觉理解与遵循指令的能力。

➤ 这个时期没做到什么

理解与生成分离（能看懂但不会画），未实现真正的统一建模。



输入图片

图片内容：
一只白色猫咪坐在木质地板上，尾巴卷曲，背景有绿色植物

输入文字

一只白色猫咪坐在木质地板上，尾巴卷曲，背景有绿色植物



无法生成图片


第八章 多模态大模型

统一建模（2024）—— 理解与生成的融合

核心思想： 将理解与生成统一于单一架构，探索不同生成范式，实现图文交织的统一多模态能力。

➤ 代表性工作

- DeepSeek JanusFlow、Emu3、Show-o



第八章 多模态大模型

Emu3

核心思想：用一个Transformer、纯下一token预测，统一处理图像、文本、视频的理解与生成。

➤ 核心架构

- **统一token化：**

散token (同一)

- **特殊标记：** [BO

[EOV]、[EOF] [


- **Transformer decoder预测下个token：**

纯下一token预测，无扩散、无CLIP

**视觉图像怎么编码成离散Token，
又怎么重构成图像？**




矢量量化变分自编码器 (VQ-VAE)



回顾

原始 VAE: 潜在变量是连续的


$$\mathcal{L} = \Sigma_x \{ |x - x'| + KL(N(\mu_x, \sigma_x^2) | N(0, 1)) \}$$




两方面优化目标:

- x 重构损失: L2 loss
- z 正则化约束: KL散度

矢量量化变分自编码器



矢量量化变分自编码器




正则化损失

$$\|z_e - z_q\|^2$$

- 约束隐层 z_e 和code book对齐

VQ-VAE作为tokenizer



Emu3

➤ 四阶段训练



预训练第一阶段：输入图文对，模型学习预测下一 token，图文混合训练。

预训练第二阶段：加入视频数据，输入视频帧序列，模型继续预测下一 token，上下文从 5120 扩至 131072。

后训练生成：用高质量图文和视频数据微调（只对视觉 token 算 loss），再用 DPO 做偏好对齐。

后训练理解：用图像-文本问答数据训练，模型看图回答文字问题（只对文本 token 算 loss）。

Emu3



第八章 多模态大模型

DeepSeek JanusFlow


核心思想： 一个Transformer，理解用自回归，生成用扩散模型。

➤ **理解任务：**

图像token + 文本token → 逐词生成答案

➤ **生成生成：**

文本token + 噪声图 → 多轮迭代
→ 完整图像



第八章 多模态大模型

统一建模（2024）—— 理解与生成的融合

核心价值：将理解与生成统一于单一架构，探索不同生成范式，实现多模态的统一建模。

➤ 这个时期做到了什么

一个模型同时处理理解与生成任务，无需拼凑多个专家模型。

➤ 这个时期没做到什么

全模态（图文音视）统一仍待探索，视频生成能力尚不成熟。




全模态爆发（2025）—— 迈向“全能”与“实时”

核心思想：向全模态（图文音视）与实时交互迈进，扩大单个模型处理的模态范围，提升跨模态理解与生成的统一性。

➤ 代表性工作

- Gemini 3, AnyGPT, Qwen3.5-Omni, 紫东太初2.0




第八章 多模态大模型

ANYGPT

核心思想：统一离散token + Next Token Prediction，不改变LLM架构，同时训练多模态理解与生成

架构设计：

- **模态分词器：**图像、语音、音乐分别用专用分词器转为离散token，与文本token共享同一词汇表。
- **训练方式：**从LLaMA-2初始化，用Next Token Prediction任务统一训练。
- **模态区分：**通过序列中的位置和任务提示自动判断



ANYGPT

预训练：从LLaMA-2初始化，使用多模态混合数据（文本、图像、语音、音乐），统一用Next Token Prediction任务训练，不改变模型架构。


后训练：使用AnyInstruct数据集（108k多轮对话，含503k语音、205k图像、113k音乐）进行指令微调，让模型学会理解和执行跨模态指令。

Qwen3-Omni

核心思想： Thinker-Talker分离架构，Thinker负责多模态理解与文本生成，Talker负责流式语音生成，两者异步协同实现低延迟实时交互。

➤ 核心架构：

- 视觉编码器：
- 音频编码器：
- Thinker：
- Talker：



多模态大模型发展阶段

