



南京航空航天大学
NANJING UNIVERSITY OF AERONAUTICS AND ASTRONAUTICS

人工智能内容生成 (AIGC) 技术与应用

第九章

视觉生成式模型

目录

- **第一节 引入**
- 第二节 图像生成VAE
- 第三节 自回归图像生成
- 第四节 扩散图像生成
- 第五节 视频生成


视觉内容

视觉内容是以图像、视频等可视化形式呈现的信息及其语义表达。

常见的视觉内容模态：



图像




视频



3D模型

视觉生成

视觉生成：根据文本、图像、语音或其他条件输入（或无条件），生成符合语义要求和视觉规律的新视觉内容。



(禁止套娃！)

视觉生成

视觉生成：根据文本、图像、语音或其他条件输入（或无条件），生成符合语义要求和视觉规律的新视觉内容。

丰富的应用场景——改变输入和输出



视觉生成
模型



线稿填充：图像->图像




视觉生成
模型



3D建模：图像->3D




视觉生成
模型



风格迁移：2图像->1图像

视觉生成

视觉生成在AIGC产品中占比巨大



美图秀秀
AI合照



剪映
AI编辑



抖音
AI特效

推荐一些好玩的软件——海报生成：Midjourney



、Canva AI



艺术海报设计，等轴，小标题“DREAMINA”，大标题“东方美学”宋体，“2024/12/5”，署名“poipoi”，极致抽象极简红色古建筑水墨画，版式高级，精准构图，大气，高级，特别，红黑金配色，留白艺术，对比，文字清晰，没有多余的元素和线条，极简主义

推荐一些好玩的软件——游戏制作：Scenario.gg



、Inworld AI



一个卡通风格的太空探险家，戴着眼罩，配有机械臂，正坐在一艘未来感十足的宇宙飞船上的旋转椅上。他轻轻地在椅子上摇晃着，靴子稳稳地踩在地板上。他微笑着，抬起一只手，做出一个手势。

视觉生成的发展现状

来玩个游戏（图灵测试）——你能分辨出哪些画是人类创作的，哪些是人工智能创作的吗？



人工智能



人类（艺考生）

视觉生成的发展现状

来玩个游戏（图灵测试）——你能分辨出哪些画是人类创作的，哪些是人工智能创作的吗？



人类（油画名家吴向东）



人工智能

视觉生成的发展现状

来玩个游戏（图灵测试）——你能分辨出哪些画是人类创作的，哪些是人工智能创作的吗？



人类（毕加索）




人工智能

达到（超越）人类绘画水平

视觉生成的发展现状

照片生成：在细节、光影与纹理上达到“以假乱真”的程度。



24年10月美国遭遇飓风灾害时，一张AI生成的“飓风中紧抱小狗的女孩”照片在社交媒体上被大量转发，引发轩然大波

视觉生成的发展现状

照片生成：在细节、光影与纹理上达到“以假乱真”的程度。




25年3月，一则“顶流男星境外豪赌输光十亿身价”的新闻在微博、小红书等平台迅速发酵，阅读量突破5亿。然而，经核查，该信息实为某网友利用AI工具生成的虚假内容

如何进行视觉生成？


依然基于前述四大类生成模型

GAN:
对抗训练替代像素级损失




曾经的主流

Diffusion models:
多步迭代去噪




现有主流

Autoregressive:
条件概率链式分解



前沿探索

VAE:
变分约束 + 编解码




更多是用于特征压缩

如何进行视觉生成?

视觉生成和文本生成的关注点不同——视觉数据的复杂性带来特殊挑战

“穿着宇航服的海豚”

VS



文本

- 离散符号空间
- 序列依赖
- 组合结构特征

视觉

- 高维连续空间
- 局部空间依赖
- 多尺度特征
- 全局语义表达

如何进行视觉生成？



视觉生成和文本生成的关注点不同——视觉数据的复杂性带来特殊挑战

1. 高维连续空间，包含的信息更多：同时承载语义、几何与外观强度信息，生成时任何一项出错都会露馅。

```

0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
0 0 0 0 1 12 0 11 39 137 37 0 152 147 84 0 0
0 0 1 0 0 0 41 160 250 255 235 162 255 238 206 11 13
0 0 0 16 9 9 150 251 45 21 184 159 154 255 233 40 0
10 0 0 0 0 0 145 146 3 10 0 11 124 253 255 107 0
0 0 3 0 4 15 236 216 0 0 38 109 247 240 169 0 11
1 0 2 0 0 0 253 253 23 62 224 241 255 164 0 5 0
6 0 0 4 0 3 252 250 228 255 255 234 112 28 0 2 17
0 2 1 4 0 21 255 253 251 255 172 31 8 0 1 0 0
0 0 4 0 163 225 251 255 229 120 0 0 0 0 0 11 0
0 0 21 162 255 255 254 255 126 6 0 10 14 6 0 0 9
3 79 242 255 141 66 255 245 189 7 8 0 0 5 0 0 0
26 221 237 98 0 67 251 255 144 0 8 0 0 7 0 0 11
125 255 141 0 87 244 255 208 3 0 0 13 0 1 0 1 0
145 248 228 116 235 255 141 34 0 11 0 1 0 0 0 1 3
85 237 253 246 255 210 21 1 0 1 0 0 6 2 4 0 0
6 23 112 157 114 32 0 0 0 0 2 0 8 0 7 0 0
0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0

```



一图胜千言

如何进行视觉生成？

视觉生成和文本生成的关注点不同——**视觉数据的复杂性带来特殊挑战**

2. 强局部相关性：图像的真实感高度依赖局部连续性与结构规律，生成模型必须在像素邻域内保持平滑/边缘清晰，否则会出现伪影。



如何进行视觉生成?

视觉生成和文本生成的关注点不同——**视觉数据的复杂性带来特殊挑战**



3. 多尺度特征层次：真实图像要求跨尺度一致，高层语义决定“是什么/结构”，低层细节决定“像不像”，生成要同时兼顾全局与细节。



什么是视觉生成？

视觉生成和文本生成的关注点不同——**视觉数据的复杂性带来特殊挑战**


4. 全局语义依赖：视觉内容的“整体语义”由分散的局部部件共同决定，生成必须让局部细节在全局上组成合理对象。



目录

- 第一节 引入
- **第二节 图像生成VAE**
- 第三节 自回归图像生成
- 第四节 扩散图像生成
- 第五节 视频生成

利用视觉特征提取网络（CNN、ResNet、ViT等）搭建编码/解码器，隐层保留相对空间位置信息



图像VAE

无法生成复杂图像，相关研究以MNIST等数据集效果展示为主



VAE生成的衣服



VAE生成的数字

更多是用于特征压缩，通常与Diffusion等配合使用

目录

- 第一节 引入
- 第二节 图像生成VAE
- **第三节 自回归图像生成**
- 第四节 扩散图像生成
- 第五节 视频生成


回顾：自回归生成模型

自回归是一种通过条件分布的乘积来建模联合数据分布的生成式模型：


$$p(x_1, x_2, \dots, x_n) = p(x_1)p(x_2|x_1)\dots p(x_n|x_1, x_2, \dots, x_{n-1})$$

$$= \prod_{i=1}^n p(x_i|x_1, x_2, \dots, x_{i-1})$$

- x_i 可以是任意顺序、任意元素划分



Autoregressive:
条件概率链式分解




视觉数据上自回归的对象 x_i 是什么？


自回归视觉生成模型

视觉自回归中不同的 x_i 元素选取方法

- **像素级自回归**: 以每个像素为 x_i (PixelRNN、PixelCNN等)




- **词元级自回归**: 将图像转化为词元序列, 以每个词元为 x_i (切分patch、基于VQ-VAE的方法等)



VQ-VAE编码



- **尺度级自回归**: 以不同尺度上的图像表示作为 x_i , 按照“由粗到细、由低分辨率到高分辨率”的顺序进行自回归建模 (VAR等)





像素级自回归视觉生成

早期尝试——PixelCNN (2016年)

- 将二维图像展成一维，对于自然图像，每个像素值的取值范围为0~255，共256个离散值
- 根据前 $i - 1$ 个像素输出第 i 个像素的概率分布 $p(x_i | x_1, \dots, x_{i-1})$ 。

Next-Pixel Prediction



Flatten



Pixel Sequence

1	2	3
4	5	6
7	8	9





1	2	3	4	5	6	7	8	9
---	---	---	---	---	---	---	---	---

像素级自回归视觉生成

早期尝试——PixelCNN (2016年)



- **类似文本的离散输出：**（以单通道图像为例）像素的颜色取值只有256种，实质为多分类任务



像素级自回归视觉生成

早期尝试——PixelCNN (2016年)


- **类似文本的离散输出：**（以单通道图像为例）像素的颜色取值只有256种，实质为多分类任务
- **自回归训练：**遮挡掉 i 及 i 之后的像素，用CNN提取前 $i - 1$ 个像素组成的图像信息



像素级自回归视觉生成

早期尝试——PixelCNN (2016年)

- **类似文本的离散输出：**（以单通道图像为例）像素的颜色取值只有256种，实质为多分类任务
- **自回归训练：**遮挡掉 i 及 i 之后的像素，用CNN提取前 $i - 1$ 个像素组成的图像信息
- **并行训练：**使用Masked_Conv，输入一幅图像，同时输出图像每一处的概率分布




像素级自回归视觉生成

早期尝试——PixelCNN (2016年)

- **类似文本的离散输出：**（以单通道图像为例）像素的颜色取值只有256种，实质为多分类任务
- **自回归训练：**遮挡掉 i 及 i 之后的像素，用CNN提取前 $i - 1$ 个像素组成的图像信息
- **并行训练：**使用Masked_Conv，输入一幅图像，同时输出图像每一处的概率分布
- **推广到RGB图像：**三个网络分别处理各个通道


缺陷——序列极长且依赖强：

- 难建模长程语义与全局结构
- 生成需逐像素串行、计算开销大



词元 (token) 级自回归

- **词元 (Token)**：把原始数据按某种规则离散化或分块编码得到的基本单元
- 模型可将词元当作序列来建模与生成




自然语言处理中的Token

通常是单词、子词、字符或者标点符号等语言的基本单元

词元 (token) 级自回归

- **词元 (Token)**：把原始数据按某种规则离散化或分块编码得到的基本单元
- 模型可将词元当作序列来建模与生成




计算机视觉

将图像编码为若干Token

词元 (token) 级自回归

连续词元回归：以Patch表征为连续Token，通过预测下一个Token表征进行自回归建模


- 切分Patch
- 每个Patch映射到一维向量 (连续Token)
- 将Token序列展平成一维序列进行自回归



词元 (token) 级自回归

连续词元回归：以Patch表征为连续Token，通过预测下一个Token表征进行自回归建模

- 切分Patch
- 每个Patch映射到一维向量 (连续Token)
- 将Token序列展平成一维序列进行自回归
- Decoder把Token映射回原始输入空间




词元 (token) 级自回归

连续词元回归：以Patch表征为连续Token，通过预测下一个Token表征进行自回归建模


- 切分Patch
- 每个Patch映射到一维向量 (连续Token)
- 将Token序列展平成一维序列进行自回归
- Decoder把Token映射回原始输入空间

局限——连续Token表征空间大：

- 缺少稳定可逆的解码约束
- 生成容易累积误差




架构：Vision Transformer



词元 (token) 级自回归

离散化词元：向量量化变分自编码器 (VQ-VAE)

- 图像编码为一系列连续Token
- 海量连续Token聚类，建立离散隐空间(codebook): $\{<\text{索引}, \text{向量}>\}$
- 每个连续Token寻找距离最近的向量，转化为离散索引的序列 (向量离散化)
- 离散索引序列自回归->索引隐空间向量变回Token表征->解码为图像



统一将文本与图像表示为序列建模，复用大模型能力，从而支持复杂组合指令的条件生成

词元 (token) 级自回归

离散词元自回归代表性工作——DALL·E (2021)

把文生图真正推到大众与研究主舞台的里程碑之一

an armchair in the
shape of an avocado. . . .




an illustration of a
baby daikon radish in a
tutu walking a dog



尺度级自回归


以不同尺度上的图像表示作为 x_i ，按照“由粗到细、由低分辨率到高分辨率”的顺序进行自回归建模



尺度级自回归


以不同尺度上的图像表示作为 x_i ，按照“由粗到细、由低分辨率到高分辨率”的顺序进行自回归建模

Stage 1: Training multi-scale VQVAE on images
(to provide the ground truth for training Stage 2)



Stage 2: Training VAR transformer on tokens


([S] means a start token with condition information)



自回归视觉生成的局限性

生成速度慢 / 推理延迟大：自回归模型通常是**按顺序**一个元素一个元素地生成（比如语言模型产生一个词 / 图像像素一块一块地），所以生成长序列 / 高分辨率图像时速度慢，延迟显著

生成顺序固定，不符合视觉逻辑：自回归通常是“**按顺序**”（如**从左到右、上到下**）生成，但图像中的**语义结构不是线性的**，比如：一张脸可以先画轮廓、再画眼睛




目录

- 第一节 引入
- 第二节 图像生成VAE
- 第三节 自回归图像生成
- **第四节 扩散图像生成**
- 第五节 视频生成

回顾：像素级扩散模型DDPM

像素级扩散模型(如DDPM)：直接在原始高维图像空间内进行加噪与去噪。




回顾：像素级扩散的局限性

- 高维空间扩散，计算开销大
 - 重构损失 (MSE) 对所有像素误差一视同仁，难以体现不同区域在感知与语义上的重要性差异
 1. 低频区域 (如背景、大块颜色)：占据图像中大部分区域，但重要性低
 2. 高频细节 (如边缘、纹理)：仅占少数像素，但对于语义表达更加重要
- 举例：高频细节轻微误差 (如边缘偏移1像素) 惩罚小，导致模型倾向于生成平滑 (模糊) 结果



潜空间扩散模型代表性产品——StableDiffusion (2022)


LDM研究团队联合Stability AI公开发布的大规模文生图扩散模型



回顾：潜空间扩散模型LDM

核心思想：将图像压缩到低维潜空间，在潜空间做扩散，再解码回像素空间

- 显著降低计算与显存开销并提升训练/采样效率
- 潜空间聚焦于重要语义，减少模糊问题






提升了扩散模型的实用性，催生了第一个大规模商用的文生图模型Stable Diffusion

StableDiffusion

StableDiffusion中的Autoencoder


- 用VAE做图像压缩 和 图像重建
- 下采样率为8: $512 \times 512 \times 3 \rightarrow 64 \times 64 \times 4$



StableDiffusion

StableDiffusion中的Autoencoder

- 用VAE做图像压缩 和 图像重建
- 下采样率为8: $512*512*3 \rightarrow 64*64*4$
- 损失函数
 - 重构损失: 逐像素误差 (如MSE)
 - 感知损失: 两张图像在预训练视觉网络的中间层向量误差, 提升**感知相似度**
 - 对抗损失: 让生成/重构结果接近 “真实图像分布” , **逼真度**。




StableDiffusion



StableDiffusion中的条件控制器

- 条件编码后的表示通过**交叉注意力机制**与去噪网络中的图像特征结合
- 在去噪过程中，条件信息动态调整生成结果，确保图像符合条件

自注意力



交叉注意力




StableDiffusion

StableDiffusion中的条件控制器

- 条件编码后的表示通过交叉注意力机制与去噪网络中的图像特征结合
- 在去噪过程中，条件信息动态调整生成结果，确保图像符合条件

可根据条件模态选择不同的编码器


- 文本: CLIP (多模态)、BERT、T5等预训练语言模型
- 语义分割图: 卷积神经网络对语义图进行编码
- 图像: VGG、ResNet



StableDiffusion

StableDiffusion中的条件控制器（文本）：CLIP(Contrastive Language-Image Pretraining)

- 通过“图文匹配”对比学习，使语义相近的图和文向量更接近
- 得到的文本表征更能表达视觉语义




StableDiffusion

StableDiffusion中的去噪网络

- 输入: $h \times w \times 4$ 的噪声图 x_t
- 输出: $h \times w \times 4$ 的噪声图 x_{t-1}

输入输出形状相同



StableDiffusion


StableDiffusion中的去噪网络——Unet架构

- 核心思想：用编码器-解码器结构与跳跃连接捕捉多尺度上下文，实现高精度预测

下采样：负责多尺度特征提取，逐步压缩空间维度以捕获高层语义。

上采样：负责特征还原，通过上采样恢复图像分辨率。


跳跃链接：核心逻辑。融合底层空间细节与高层抽象语义，弥补下采样中的信息损失。



StableDiffusion

StableDiffusion中的去噪网络——Unet架构

- 卷积后面加入Spatial Transformer, 从而 (1) 引入控制条件表征 (2) 提升全局建模能力





StableDiffusion

StableDiffusion中的去噪网络——Unet架构

Unet的优点

- 严格的空間同构与细节保真
- 适配逐步去噪的多尺度感知
- 天然契合层次化条件控制



UNet的局限性

- **可扩展性受限**: CNN而非Transformer架构, 难以享受scaling law的模型扩展红利
- **全局交互受限**: CNN架构偏向局部特征提取
- **通用性受限**: 与 2D 空间维度 (下采样/上采样) 强绑定, 缺乏模态通用性

StableDiffusion

Diffusion Transformer (DiT) : 使用Transformer作为去噪主干网络

- 将图像潜特征转化为Latent Patches序列
- 以Transformer架构统一生成图像与文本条件的底层表征



可扩展性强，直接全局交互，容易应用到其他模态


StableDiffusion

Multi-Modal Diffusion Transformer (MM-DiT)

提出于Stable Diffusion 3 技术报告，延用于主流生成网络

核心架构：双流联合注意力

- 不同模态Token序列在注意力层前后由独立的网络处理成token
- 联合注意力层进行多模态统一全局注意力交互，随后拆分回各自的流
- 时间步作为全局条件分别“调制（Modulation）”各模态Token



如今的图像生成效果

即梦: <https://jimeng.jianying.com/>

吊卡公仔设计，塑料包装内摆放着一个女孩公仔，包装顶部有文字“这么近那么美-周末到河北”，包装盒内有掐丝珐琅的文字“河北”冰箱贴，文字由建筑纹样和花卉组成，包装内有赵州桥的模型和错金铜博山炉模型，底部有文字“WODIBRAND DESIGN”



鱼眼镜头，一只带着墨镜的橘猫戴着围巾和毛绒耳罩，站在雪地上微笑自拍，背后是连绵的雪山。它的背包里探出一只小黄鸭玩偶



目录

- 第一节 引入
- 第二节 图像生成VAE
- 第三节 自回归图像生成
- 第四节 扩散图像生成
- 第五节 视频生成

视频生成是视觉生成的另一重要方向，具有巨大的商业价值



AI日报：快手推出AI视频制作助手Kwali；字节跳动推出USO模型；OpenAI推出ChatGPT开发者模式

发布于最新AI日报 发布时间：2025年9月11号 16:03 阅读：2分钟

欢迎来到【AI日报】栏目!这里是您每天探索人工智能世界的指南，每天我们为您呈现AI领域的热点内容，聚焦开发者，助您洞悉技术趋势、了解创新AI产品应用。

新鲜AI产品点击了解：<https://app.aibase.com/zh>

1、快手推出 AI 视频制作助手 Kwali，轻松一语生成短视频!

快手推出的 Kwali AI 视频制作助手通过云端多 Agent 框架，简化了视频制作流程。用户只需输入需求，Kwali 即可自动拆解卖点、受众和情境标签，并生成脚本、匹配镜头、剪辑合成，大幅提升了效率。

AI带来短视频创作浪潮 年轻人涌进抖音创作者大会


科创板日报 2025-09-22 07:48 发布于上海 财联社旗下《科创板日报》官方账号

+关注

《科创板日报》9月22日讯（记者 张洋洋）“平台内使用AI创作的稿件量增长了91%。”这是在2025抖音创作者大会上，抖音副总裁陈都烨公布的一组数据。

在生成式AI全面渗透各行各业的大背景下，AI正在成为短视频行业的核心变量。无论是自动生成脚本、智能剪辑，还是AI绘画、音乐创作，都在重塑内容生产方式。

视频生成演示

电影片段生成: Sora  、 Pika 

一部电影预告片，讲述了一位30岁的太空人戴着红色羊毛针织摩托车头盔，在蓝天、盐漠、电影风格下冒险的故事，采用35毫米胶片拍摄，色彩鲜艳。




视频生成演示

电影片段生成: Sora




、Pika



一辆伤痕累累、经过大幅改装的拉力赛车疾驰在无边无际的风雕沙漠沙丘上，其尖刺状的装甲怒然挺立，焊接的金属表面闪烁着被风沙侵蚀的痕迹。其规模极为壮观——沙丘的峰顶犹如古老的遗迹，吞噬着四周的一切。

如何进行视频生成？

视频：由**连续的一系列静态图像帧**，按照一定时间顺序播放，从而让人产生**运动视觉**的一种媒体形式



视频是图像的序列！

逐帧生成图像，直接拼接成视频？

可以生成图片 ? = 可以生成视频




视频生成

逐帧生成图像，直接拼接成视频？

可以生成图片



可以生成视频




核心挑战——时序一致性

- **时间一致性缺失**：逐帧生成没有显式建模运动与相机轨迹，容易闪烁（flicker）、跳变。
- **身份/外观漂移**：人物脸、衣服纹理、物体形状会在相邻帧变化，出现“变身”。
- **物理与遮挡不自洽**：运动连续性、遮挡关系、光照随时间变化难以保持一致。


视频生成

解决方案：时空联合生成

把视频视为 $H \times W \times 3 \times T$ 的整体，在生成过程中同时建模空间与时间依赖，从而保证帧间一致性。



逐帧生成




时空联合生成

扩散视频生成模型Video Diffusion Model

Video Diffusion Model(2022): 早期的扩散视频生成模型，将去噪网络扩展到3D


- 网络架构：3D Unet + 时空注意力网络
- 对时间做相对位置编码



扩散视频生成模型Video Diffusion Model

Video Diffusion Model(2022): 早期的扩散视频生成模型，将去噪网络扩展到3D

- 网络架构: 3D Unet + 时空注意力网络
- 对时间做相对位置编码




3D Unet: 将2D卷积改为3D卷积

扩散视频生成模型Video Diffusion Model

Video Diffusion Model(2022): 早期的扩散视频生成模型，将去噪网络扩展到3D

- 网络架构：3D Unet + **时空注意力网络**
- 对时间做相对位置编码




- **空间注意力:** 对于每个时间切片，在空间维度做注意力
- **时间注意力:** 对于每个空间位置，在时间维度做注意力

扩散视频生成模型SoRA

SoRA: 现象级的视频生成模型


- 隐空间视频扩散生成
- DiT去噪主干(比Unet更适合捕捉长文本控制条件和长时语义依赖)
- 高效灵活地处理不同视频分辨率尺寸的预训练模型



扩散视频生成模型SoRA

视频潜空间加噪/去噪过程

视频在潜空间
中的稠密表示




扩散过程

逐步从噪声还
原的过程

切分视频Patches

切分视频Patches

将几帧图像数据在时间和空间轴上同时切割，输出一个三维的数据块，把每一个三维的数据块转换成一个patch。



分层结构中的切分

总结

- 第一节 引入
- 第二节 图像生成VAE
- 第三节 自回归图像生成
- 第四节 扩散图像生成
- 第五节 视频生成